

Part B - Calculation Exercises

Ex 1:

$$(D_1): [1, 0, 1, 1, 0]$$

$$(D_2): [0, 1, 1, 1, 0]$$

$$(D_3): [1, 0, 0, 1, 1]$$

Ex 2:

$$tf(cat, D_1) = \frac{1}{3}$$

$$tf(eats, D_1) = \frac{1}{3}$$

$$tf(fish, D_1) = \frac{1}{3}$$

$$\rightarrow \sum tf(t, D_1) = 1$$

Ex 3:

$$idf(cat) \approx 0,176$$

$$idf(dog) \approx 0,477$$

$$idf(eats) \approx 0,176$$

$$idf(fish) = 0$$

$$idf(likes) \approx 0,477$$

$\rightarrow$ Term có idf thấp nhất là fish. Do fish xuất hiện ở tất cả các văn bản

Ex 4:

$$tf-idf(cat, D_1) = tf(cat, D_1) \cdot idf(cat) \approx 0,058$$

$$tf-idf(eats, D_1) \approx 0,058$$

$$tf-idf(fish, D_1) = 0$$

$\rightarrow$ tfidf của fish bằng 0 bởi vì từ mất ý nghĩa,

tfidf sẽ phát những term xuất hiện quá phổ biến trong toàn bộ corpus

Ex 5:

$$x = [1, 1, 1]$$

$$y = [1, 1, 0]$$

$$\cos(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2} = \frac{(1.1) + (1.1) + (1.0)}{\sqrt{1^2 + 1^2 + 1^2} \cdot \sqrt{1^2 + 1^2 + 0^2}} = \frac{2}{\sqrt{6}} \approx 0.816$$

cos similarity không bằng $\frac{2}{3}$ vì phép toán này đo độ lệch

góc của 2 vector trong không gian đa chiều

Ex 6:

1. Document có similarity cao nhất là D_1
2. Document có similarity thấp nhất là D_3
3. Term có idf thấp sẽ là medical và image
4. Nếu bỏ idf chỉ sử dụng count vector thì ranking sẽ không thay đổi

Part C - Prediction Before

Part D - Experiment 1

- Một document chỉ sử dụng một phần rất nhỏ vocabulary nhưng vector vẫn có chiều V vì để so sánh hai văn bản bất kỳ, ví dụ như tính cosine similarity $\rightarrow$ các vector văn bản phải nằm trong cùng một không gian vector.

- Một term xuất hiện rất nhiều trong corpus không nhất thiết có TF IDF cao vì IDF sẽ tiến dần về 0
 $\rightarrow$ TF IDF nhỏ

- Một term có IDF cao không nhất thiết có TF IDF cao trong mọi document. IDF cao tức là từ đó hiếm gặp. Nếu một document không chứa từ đó $\rightarrow DF=0$
 $\rightarrow$ TF IDF = 0

Part E - Core Implementation

Sự khác biệt đến từ convention mà định của thư viện và cách normalization.

- TF của sklearn sử dụng count thuần túy:

$$tf(t, d) = c(t, d)$$

- IDF của sklearn không sử dụng log mà dùng ln
 $idf(t) = \ln\left(\frac{1+N}{1+df(t)}\right) + 1$

Part F - Experiment 2

- Lowercase sẽ làm mất khả năng phân biệt từ điển. Ngược lại sẽ gây mất ngữ nghĩa (công ty Apple $\neq$ apple)

- Stop word removal gây mất ngữ nghĩa

- Loại punctuation sẽ làm mất toàn bộ token chứa kí tự đặc biệt

- Pipeline B tạo ra ma trận sparse nhất.

- Pipeline B cho chất lượng search tốt nhất. Nó bỏ qua những stopwords, dấu câu, tập trung vào các content words.

- Search tốt hơn $\neq$ vocab nhỏ hơn.



Part I - Error Analysis

*1) 2 Query có kết quả tốt:

- "Medical image classification"

15. Learning Check

Question 1: TF-IDF có tạo ra một KGV có số chiều (v) bằng tổng số từ vựng duy nhất của toàn bộ corpus. Hầu hết các chiều trong vector của tài liệu đó có giá trị 0 $\rightarrow$ sparse matrix

Question 2:

$$\text{idf}(t) = \log\left(\frac{N}{\text{df}(t)}\right) \text{ Mà } \text{df}(t) \rightarrow N$$

$$\rightarrow \text{idf}(t) \rightarrow 0$$

Question 3: Một từ có IDF cao chứng tỏ nó hiếm và đặc trưng trong toàn corpus. Một từ đó hoàn toàn $\equiv$ xuất hiện trong tài liệu $\rightarrow \text{TF} = 0$
 $\rightarrow \text{TF-IDF} = 0$

Question 4:

Một văn bản dài và một văn bản ngắn nhưng viết về cùng chủ đề sẽ có hướng vector gần như song song và đạt điểm cosine cao.

Question 5:

Preprocessing cần thực hiện trực tiếp vào đối tượng của token. Việc lowercasing sẽ gộp các biến thể từ lại, tăng DF và giảm IDF.